T.C.
İSTANBUL BEYKENT ÜNİVERSİTESİ
MÜHENDİSLİK – MİMARLIK FAKÜLTESİ
YAPAY ZEKAYA GİRİŞ DERSİ

LİNEER REGRESYON ALGORİTMASI İLE SATIŞ DEĞERİ TAHMİNİ UYGULAMASI

Mert Uğur
Tolga Uslu

İçindekiler

1. ÖZET 3
2. GİRİŞ 3
2.1 Lineer Regresyon Algoritmasına Genel Bakış 3
2.2 Lineer Regresyonun Tarihçesi ve Bilimsel Temeli 3
2.3 Algoritmanın Çalışma Mantığı 4
2.4 Lineer Regresyonun Kullanım Alanları 5
2.4.1 Sağlık Alanında Kullanımı 5
2.4.2 Finans Alanında Kullanımı 6
2.4.3 Eğitim Alanında Kullanımı 6
2.4.4 Mühendislik Alanında Kullanımı 7
2.4.5 Pazarlama ve İşletme Alanında Kullanımı 7
2.5 Sürdürülebilir Kalkınma Amaçları Kapsamında Katkısı 8
3. YÖNTEM 9
3.1 Problemin Tanımlanması 9
3.2 Veriyi Anlama (Data Understanding) 10
3.2.1 Keşifçi Veri Analizi (EDA) 11
3.3 Veriyi Hazırlama (Data Preparation) 11
3.4 Modelleme (Modeling) 12
3.4.1 Senaryo 1: Holdout Yöntemi (%80 Eğitim - %20 Test) 13
3.4.2 Senaryo 2: 10-Katlı Çapraz Geçerleme (10-Fold Cross-Validation) 13
3.4.3 Hiperparametre Ayarları ve Model Konfigürasyonu 13
3.5 Bulgular 14
3.5.1 Performans Metriklerinin Karşılaştırılması 14
3.5.2 Görsel Analizlerin Yorumlanması ..... **Error! Bookmark not defined.**
4. SONUÇ VE ÖNERİLER 14
5. KAYNAKÇA 15

1. ÖZET

Bu çalışmada, makine öğrenmesinin temel yöntemlerinden biri olan Lineer Regresyon algoritması hem teorik hem de uygulamalı bir perspektifle ele alınmıştır. Çalışmanın teorik bölümünde Lineer Regresyonun tarihsel gelişimi, matematiksel çalışma mantığı ve sağlık, finans, eğitim, mühendislik ile pazarlama gibi farklı alanlardaki kullanımları literatür destekli biçimde incelenmiştir. Uygulama bölümünde ise Kaggle platformundan temin edilen 21.613 örneklik King County konut satış veri seti üzerinde, CRISP-DM metodolojisi çerçevesinde konut fiyat tahmini gerçekleştirilmiştir. Veri ön işleme aşamasında gereksiz nitelikler ("id", "date") ayıklanmış ve tüm sayısal değerler [0, 1] aralığına normalize edilmiştir. Modelleme sürecinde Weka 3.8.6 platformu kullanılarak Lineer Regresyon algoritması, Holdout (%80 eğitim – %20 test) ve 10-Katlı Çapraz Geçerleme olmak üzere iki farklı test senaryosuyla değerlendirilmiştir. Elde edilen sonuçlara göre 10-Katlı Çapraz Geçerleme yöntemiyle 0,8356 korelasyon katsayısı, 0,0165 MAE ve 0,0264 RMSE değerlerine ulaşılmıştır. Bu sonuçlar, modelin gerçek konut fiyatları ile tahminleri arasında güçlü bir ilişki kurabildiğini göstermektedir. Çalışma ayrıca Birleşmiş Milletler Sürdürülebilir Kalkınma Amaçlarından SKA 11: Sürdürülebilir Şehirler ve Topluluklar hedefiyle ilişkilendirilmiş olup konut piyasasında veriye dayalı karar destek süreçlerine katkı sağlamayı amaçlamaktadır.

2. GİRİŞ

2.1 Lineer Regresyon Algoritmasına Genel Bakış

Lineer regresyon, bir sonucun hangi faktörlere bağlı olarak değiştiğini incelemek ve bu ilişki üzerinden sayısal tahmin yapmak için kullanılan temel bir makine öğrenmesi yöntemidir. Bu yöntemde tahmin edilmek istenen değer bağımlı değişken, bu değeri etkilediği düşünülen veriler ise bağımsız değişken olarak adlandırılır. Örneğin bir öğrencinin sınav notu tahmin edilmek isteniyorsa sınav notu bağımlı değişken, çalışma süresi gibi sonucu etkileyen bilgiler ise bağımsız değişkendir. Lineer regresyon geçmiş verilerden yararlanarak bu değişkenler arasındaki doğrusal ilişkiyi modellemeye çalışır ve elde edilen model sayesinde yeni veriler için tahmin yapılabilir.

2.2 Lineer Regresyonun Tarihçesi ve Bilimsel Temeli

Lineer regresyonun tarihsel temeli 19. yüzyılın başlarında geliştirilen en küçük kareler yöntemine dayanmaktadır. Bu yöntem gözlemlerden elde edilen gerçek değerler ile modelin tahmin ettiği değerler arasındaki farkları en aza indirmeyi amaçlayan matematiksel bir yaklaşımdır. En küçük kareler yöntemi ilk kez Adrien-Marie Legendre tarafından 1805 yılında yayımlanan *Nouvelles méthodes pour la détermination des orbites des comètes* adlı çalışmada açık biçimde ortaya konulmuştur [1].

Legendre bu çalışmasında kuyruklu yıldızların yörüngelerinin belirlenmesi sırasında gözlem hatalarını azaltmak ve verilere en uygun matematiksel modeli oluşturmak için bu yöntemi kullanmıştır.

Daha sonra Carl Friedrich Gauss, 1809 yılında yayımladığı *Theoria Motus Corporum Coelestium* adlı eserinde en küçük kareler yöntemini astronomik hesaplamalar bağlamında ele almış ve yöntemin bilimsel temellerinin güçlenmesine katkı sağlamıştır [2]. Bu dönemden itibaren regresyon yaklaşımı özellikle astronomi ve ölçüm hatalarının azaltılması gibi alanlarda kullanılan matematiksel bir yöntem olarak gelişmeye başlamıştır.

"Regresyon" kavramının istatistik alanında yaygınlaşmasında ise Francis Galton önemli bir role sahiptir. Galton, 1886 yılında yayımladığı *Regression Towards Mediocrity in Hereditary Stature* adlı çalışmasında kalıtım ve boy uzunluğu arasındaki ilişkiyi incelemiş ve "regresyon" kavramının istatistiksel analizlerde kullanılmasına öncülük etmiştir [3].
Zamanla lineer regresyon, yalnızca astronomi veya kalıtım çalışmalarıyla sınırlı kalmamış; ekonomi, sağlık, mühendislik, eğitim, finans ve sosyal bilimler gibi birçok alanda kullanılan temel bir analiz ve tahmin yöntemi haline gelmiştir. Günümüzde ise lineer regresyon, makine öğrenmesi ve veri bilimi alanlarında hem değişkenler arasındaki ilişkiyi açıklamak hem de sayısal tahminler yapmak amacıyla kullanılan en temel algoritmalardan biri olarak değerlendirilmektedir.

2.3 Algoritmanın Çalışma Mantığı

Lineer regresyon, geçmiş verilerdeki ilişkileri inceleyerek yeni bir sayısal değer tahmin etmeye çalışır. Bu yöntemde ilk olarak tahmin edilmek istenen sonuç belirlenir. Bu sonuç bağımlı değişken olarak adlandırılır. Sonucu etkilediği düşünülen veriler ise bağımsız değişkenler olarak ifade edilir. Örneğin bir evin fiyatı tahmin edilmek isteniyorsa ev fiyatı bağımlı değişken metrekare, oda sayısı, bina yaşı ve konum gibi bilgiler bağımsız değişken olarak değerlendirilebilir.

Lineer regresyonun temel amacı, bağımsız değişkenler ile bağımlı değişken arasındaki ilişkiyi en iyi temsil eden doğrusal modeli oluşturmaktır. Basit lineer regresyonda bu ilişki $y = a + bx$ formülüyle ifade edilir. Bu formülde y tahmin edilen değeri, x sonucu etkileyen değişkeni, b değişkenin sonuca olan etkisini gösteren eğimi, a ise sabit başlangıç değerini temsil eder. Model eldeki veri noktalarının genel dağılımına en uygun doğruyu bulmaya çalışır.

Modelin yaptığı tahminler ile gerçek değerler arasında fark oluşabilir. Bu fark hata olarak adlandırılır. Lineer regresyon, bu hataları mümkün olduğunca azaltmayı hedefler. Bunun için genellikle en küçük kareler yöntemi kullanılır. Bu yöntemde her tahmin hatasının karesi alınır ve

toplam hata en düşük olacak şekilde modelin katsayıları belirlenir. Böylece model, geçmiş verilerdeki ilişkiyi öğrenerek yeni veriler için tahmin yapabilecek hale gelir.

Tablo 1. Lineer Regresyonun Çalışma Süreci

Sıra	Süreç	Açıklama
1	Veri setinin hazırlanması	Geçmiş veriler düzenlenir ve model için uygun hale getirilir.
2	Değişkenlerin belirlenmesi	Tahmin edilecek değer bağımlı değişken, onu etkileyen bilgiler bağımsız değişken olarak seçilir.
3	Doğrusal modelin kurulması	Değişkenler arasındaki ilişkiyi temsil eden doğrusal model oluşturulur.
4	Tahminlerin yapılması	Model, bağımsız değişkenlere göre bağımlı değişken için tahmin üretir.
5	Hata değerinin hesaplanması	Gerçek değer ile tahmin edilen değer arasındaki fark hesaplanır.
6	Hatanın azaltılması	En küçük kareler yöntemiyle toplam hata en aza indirilmeye çalışılır.
7	Yeni veriler için tahmin yapılması	Model, öğrendiği ilişkiyi kullanarak yeni veriler için sayısal tahmin yapar.

2.4 Lineer Regresyonun Kullanım Alanları

Lineer regresyon, sayısal değerlerin tahmin edilmesi ve değişkenler arasındaki ilişkinin açıklanması amacıyla farklı alanlarda yaygın olarak kullanılan temel bir yöntemdir. Özellikle tahmin edilmek istenen sonucun sürekli sayısal bir değer olduğu durumlarda etkili bir modelleme yaklaşımı sunar. Bu nedenle sağlık, finans, eğitim, mühendislik, enerji, pazarlama ve işletme gibi birçok alanda karar destek, tahmin ve analiz süreçlerinde kullanılmaktadır.

2.4.1 Sağlık Alanında Kullanımı

Sağlık alanında lineer regresyon, klinik veriler arasındaki ilişkileri incelemek ve sayısal sağlık sonuçlarını tahmin etmek amacıyla kullanılmaktadır. Schober ve Vetter tarafından yapılan çalışmada lineer regresyonun tıbbi araştırmalardaki temel kullanım amacı açıklanmıştır [4]. Çalışmada lineer regresyonun, bir veya daha fazla bağımsız değişken ile sürekli sayısal bir sonuç değişkeni arasındaki ilişkiyi ölçmek için kullanılan bir yöntem olduğu belirtilmiştir. Ayrıca bu yöntemin, değişkenler arasındaki ilişkinin yönünü ve gücünü ortaya koyabildiği ve sonuç değişkeninin tahmin edilmesinde kullanılabildiği ifade edilmiştir. Bu nedenle lineer regresyon, sağlık alanında klinik ölçümlerin

değerlendirilmesi, risk faktörlerinin yorumlanması ve hastalara ait sayısal sonuçların tahmin edilmesi açısından önemli bir yöntemdir.

Taloba ve arkadaşları tarafından gerçekleştirilen uygulamalı çalışmada ise lineer regresyon, hastane yatışı ve tıbbi bakım maliyetlerinin tahmin edilmesi amacıyla kullanılmıştır [5]. Araştırmada geçmiş sağlık verileri kullanılarak gelecekte oluşabilecek toplam sağlık maliyetlerinin öngörülmesi hedeflenmiştir. Çalışmada lineer regresyon, sağlık maliyetlerini tahmin etmek için kullanılan makine öğrenmesi yöntemlerinden biri olarak değerlendirilmiş ve elde edilen sonuçlara göre toplam sağlık maliyetlerinin tahmininde %97,89 doğruluk oranına ulaşmıştır. Bu sonuç, lineer regresyonun sağlık alanında yalnızca değişkenler arasındaki ilişkiyi açıklamak için değil, aynı zamanda maliyet tahmini, kaynak planlaması ve karar destek süreçlerinde de kullanılabileceğini göstermektedir.

2.4.2 Finans Alanında Kullanımı

Finans alanında lineer regresyon, geçmiş piyasa verilerinden yararlanarak gelecekteki fiyat hareketlerini tahmin etmek ve finansal değişkenler arasındaki ilişkiyi incelemek amacıyla kullanılmaktadır. Sangeetha ve Alfia tarafından gerçekleştirilen çalışmada, S&P 500 endeksine ait finansal değerlerin tahmin edilmesi için Evaluated Linear Regression tabanlı bir makine öğrenmesi yaklaşımı kullanılmıştır [6]. Araştırmada açılış fiyatı, kapanış fiyatı, en düşük fiyat, en yüksek fiyat ve işlem hacmi gibi değişkenler üzerinden borsa verileri analiz edilmiştir. Çalışmada model performansı R^2 değeri ile değerlendirilmiş ve lineer regresyon tabanlı modelin R^2 değeri 0,428, düzeltilmiş R^2 değeri ise 0,352 olarak raporlanmıştır. Bu sonuç, lineer regresyonun finansal piyasalarda geçmiş verilerden hareketle fiyat tahmini yapmak ve piyasa değişkenleri arasındaki ilişkiyi analiz etmek için kullanılabileceğini göstermektedir.

Antad ve arkadaşları tarafından yapılan başka bir çalışmada ise lineer regresyon, hisse senedi fiyat tahmini yapan bir web uygulaması geliştirmek amacıyla kullanılmıştır [7]. Çalışmada Python, Django framework ve Yahoo Finance verileri kullanılarak geçmiş hisse senedi verilerinden gelecekteki fiyatların tahmin edilmesi hedeflenmiştir. Araştırmada lineer regresyonun tercih edilme nedeni, geçmiş finansal veriler üzerinden anlaşılır ve uygulanabilir tahminler üretebilmesidir. Bu yönüyle çalışma, lineer regresyonun finans sektöründe borsa tahmini, yatırım analizi ve karar destek sistemleri gibi uygulamalarda kullanılabileceğini göstermektedir.

2.4.3 Eğitim Alanında Kullanımı

Eğitim alanında lineer regresyon, öğrencilerin akademik performansını tahmin etmek ve başarıyı etkileyen faktörleri analiz etmek amacıyla kullanılmaktadır. Huang ve Fang tarafından gerçekleştirilen çalışmada, lineer regresyon modelleri mühendislik öğrencilerinin “Engineering Dynamics” dersindeki akademik performansını tahmin etmek için kullanılmıştır [8]. Araştırmada öğrencilerin önceki ders

başarıları ve dönem içi sınav sonuçları gibi değişkenlerden yararlanılarak ders performansının önceden tahmin edilmesi amaçlanmıştır. Çalışmada geliştirilen regresyon modelleri sayesinde öğrencilerin başarı durumlarının dönem içerisinde öngörülebileceği ve bu tahminlerin, akademik olarak risk altında olan öğrencilerin erken belirlenmesine katkı sağlayabileceği belirtilmiştir. Bu yönüyle lineer regresyon, eğitim alanında öğrenci başarısını tahmin etme, öğretim sürecini iyileştirme ve erken destek mekanizmaları geliştirme amacıyla kullanılabilecek önemli bir yöntemdir.

2.4.4 Mühendislik Alanında Kullanımı

Mühendislik alanında lineer regresyon, sistem performansını analiz etmek, üretim süreçlerini değerlendirmek ve geleceğe yönelik sayısal tahminler yapmak amacıyla kullanılmaktadır. Kpomonè ve arkadaşları tarafından gerçekleştirilen çalışmada, elektrik tüketimini tahmin etmek için çoklu lineer regresyon modeli kullanılmıştır [9]. Araştırmada elektrik tüketim verileri ile sıcaklık, bağıl nem, yağış, rüzgâr hızı ve güneş ışınımı gibi çevresel değişkenler analiz edilmiştir. Çalışmada lineer regresyonun tercih edilme nedeni, elektrik tüketimi ile bu değişkenler arasındaki ilişkiyi modelleyerek gelecekteki tüketim değerlerini tahmin edebilmektir. Model performansı MAE, MSE, RMSE ve R^2 değerleriyle değerlendirilmiş; en iyi modelde R^2 değeri %77,284 olarak raporlanmıştır. Bu sonuç, lineer regresyonun mühendislik alanında sistemlerin davranışını analiz etme, tüketim tahmini yapma ve karar destek süreçlerinde kullanılabilecek etkili bir yöntem olduğunu göstermektedir.

2.4.5 Pazarlama ve İşletme Alanında Kullanımı

Pazarlama ve işletme alanında lineer regresyon, reklam harcamalarının satış üzerindeki etkisini incelemek ve gelecekteki satış miktarını tahmin etmek amacıyla kullanılmaktadır. “Prediction of Sales Based on an Effective Advertising Media Sale Data” adlı çalışmada, reklam medya verileri kullanılarak satış tahmini yapılması amaçlanmıştır [10]. Çalışmada televizyon, radyo ve gazete reklam harcamaları gibi değişkenler üzerinden satış değerleri analiz edilmiş ve lineer regresyon modeli kullanılmıştır. Lineer regresyonun tercih edilme nedeni, reklam harcamaları ile satış miktarı arasındaki ilişkiyi ölçebilmesi ve bu ilişkiye göre gelecekteki satışları tahmin edebilmesidir. Bu yönüyle lineer regresyon, işletmelerin reklam bütçelerini daha etkili planlamasına, satış tahminleri yapmasına ve pazarlama kararlarını veriye dayalı olarak desteklemesine katkı sağlamaktadır.

Genel olarak değerlendirildiğinde lineer regresyon; sağlık, finans, eğitim, mühendislik ve pazarlama gibi farklı alanlarda sayısal tahmin yapmak ve değişkenler arasındaki ilişkileri açıklamak amacıyla kullanılmaktadır. Literatürdeki çalışmalar incelendiğinde, lineer regresyonun özellikle anlaşılır yapısı, yorumlanabilir sonuçlar üretmesi ve farklı veri türlerine uygulanabilmesi nedeniyle

tercih edildiği görülmektedir. Bu nedenle lineer regresyon, hem akademik araştırmalarda hem de gerçek dünya problemlerinde karar destek ve tahmin süreçlerinde kullanılan temel yöntemlerden biri olarak değerlendirilebilir.

2.5 Sürdürülebilir Kalkınma Amaçları Kapsamında Katkısı

Bu çalışma, Birleşmiş Milletler Sürdürülebilir Kalkınma Amaçları kapsamında SKA 11: Sürdürülebilir Şehirler ve Topluluklar amacıyla ilişkilendirilebilir. SKA 11, şehirlerin ve yerleşim alanlarının daha kapsayıcı, güvenli, dayanıklı ve sürdürülebilir hale getirilmesini hedeflemektedir. Konut piyasası, şehir yaşamının temel bileşenlerinden biri olduğu için konut fiyatlarının nesnel, ölçülebilir ve veriye dayalı biçimde analiz edilmesi sürdürülebilir şehirleşme açısından önemli bir katkı sunmaktadır.

Bu projede King County konut satış veri seti kullanılarak konut fiyatlarını etkileyen fiziksel, yapısal ve çevresel faktörler Lineer Regresyon algoritmasıyla analiz edilmiştir. Çalışmanın temel amacı, bir konutun satış değerini en düşük hata payıyla tahmin etmek ve fiyat üzerinde etkili olan değişkenleri daha anlaşılır hale getirmektir. Veri setinde yer alan yaşam alanı büyüklüğü, konum, oda sayısı, kat sayısı, konut durumu ve satış fiyatı gibi değişkenler, konut piyasasının daha sistematik biçimde incelenmesine olanak sağlamaktadır. Raporda da proje odağının, konut satış değerini fiziksel, yapısal ve çevresel faktörler üzerinden tahmin etmek olduğu belirtilmektedir.

Modelleme sonucunda elde edilen bulgular, konut fiyatlarının özellikle yaşam alanı büyüklüğü, konum ve fiziksel durum gibi değişkenlerden etkilendiğini göstermektedir. Çalışmada 10-Katlı Çapraz Geçerleme yöntemiyle elde edilen 0.8356 korelasyon katsayısı, gerçek konut fiyatları ile modelin tahminleri arasında güçlü bir ilişki bulunduğunu ortaya koymaktadır. Bu sonuç, geliştirilen modelin emlak piyasasında veri odaklı fiyatlandırma kararlarını destekleyebilecek güvenilir bir araç olarak değerlendirilebileceğini göstermektedir.

Bu bağlamda proje, konut değerlerinin daha şeffaf, tutarlı ve ölçülebilir biçimde analiz edilmesine katkı sağlamaktadır. Alıcılar, satıcılar, emlak uzmanları ve şehir planlamacıları için daha bilinçli karar alma süreçlerini desteklemesi, çalışmanın toplumsal boyutunu oluşturmaktadır. Aynı zamanda konut fiyatlarını etkileyen faktörlerin veri analiziyle ortaya konulması, şehirlerdeki konut piyasasının daha adil ve sürdürülebilir biçimde değerlendirilmesine yardımcı olabilir. Bu nedenle Lineer Regresyon tabanlı konut fiyat tahmin modeli, SKA 11: Sürdürülebilir Şehirler ve Topluluklar amacına veri odaklı karar destek yaklaşımıyla katkı sağlayan bir mühendislik çözümü olarak değerlendirilebilir.

3. YÖNTEM

Bu çalışmada veri analizi ve modelleme sürecimizi, veri madenciliği dünyasında standart kabul edilen CRISP-DM metodolojisi üzerine inşa ettik. Bu yaklaşım sayesinde projenin en başındaki problemin tanımlanmasından sonuçların değerlendirilmesine kadar tüm adımları belirli bir disiplin ve ölçülebilir bir yapı içinde yürüttük. Süreç kapsamında ilk olarak konut fiyatlarını etkileyen temel parametreleri belirleyip tahminleme ihtiyacını netleştirerek işe başladık; ardından King County veri setinin yapısal özelliklerini derinlemesine inceleyerek istatistiksel özetlerini çıkardık.

Modeli eğitme aşamasına geçmeden önce, veri setindeki gereksiz nitelikleri temizleyip sonuçların çok daha tutarlı olması için gerekli normalizasyon işlemlerini titizlikle uyguladık. Modelleme aşamasında ise Lineer Regresyon algoritmasını hem Holdout hem de Cross-Validation gibi farklı test senaryolarıyla eğiterek performansını detaylıca gözlemledik. Son aşamada ise elde ettiğimiz MAE, RMSE ve Korelasyon gibi kritik hata metriklerini görsel analizlerle birleştirip yorumlayarak çalışmamızı başarıyla tamamladık

3.1 Problemin Tanımlanması

Bu çalışmada temel odak noktamız, gayrimenkul piyasasındaki bir konutun satış değerini; fiziksel, yapısal ve çevresel faktörler üzerinden en düşük hata payıyla tahmin edebilmektir. Konut fiyatları, doğası gereği pek çok değişkenin iç içe geçtiği karmaşık bir yapı sunduğu için, bu ilişkiyi anlamlı bir matematiksel zemine oturtmak amacıyla bilimsel modelleme yaklaşımlarını tercih ettik.

Literatürde bu problem, 1960'lı yıllardan itibaren Andrew Court ve Kelvin Lancaster gibi iktisatçıların temellerini attığı "Hedonik Fiyatlandırma" teorisiyle ele alınmaya başlanmıştır. Daha sonra Sherwin Rosen (1974), konutun her bir özelliğinin (oda sayısı, manzara, konum) fiyata olan marjinal katkısını ölçen matematiksel modeli standart hale getirmiştir. Günümüzde ise veri bilimciler ve araştırmacılar, klasik istatistiksel yöntemlerin ötesine geçerek; konut fiyatlarını tahmin etmek için Rastgele Orman (Random Forest), Destek Vektör Makineleri (SVM) ve Yapay Sinir Ağları (YSA) gibi karmaşık makine öğrenmesi algoritmalarını kullanmaktadır.

Özellikle bu çalışmada kullandığımız King County veri seti üzerinde daha önce yapılan araştırmalar, basit doğrusal modellerin bile konutun yaşam alanı (sqft_living) gibi temel değişkenleri kullanarak oldukça isabetli sonuçlar verdiğini göstermiştir. Biz de bu birikimden yola çıkarak, hem sonuçların açıklanabilirliği hem de akademik dünyada hala en temel referans noktası kabul edilmesi sebebiyle Lineer Regresyon yöntemini temel aldık. Bu analizleri gerçekleştirmek için de dünya çapındaki araştırmacıların ortak platformu olan Kaggle üzerinden temin edilen, 21.613 örneklik zengin içeriğe sahip "King County House Sales" veri setinden yararlandık.

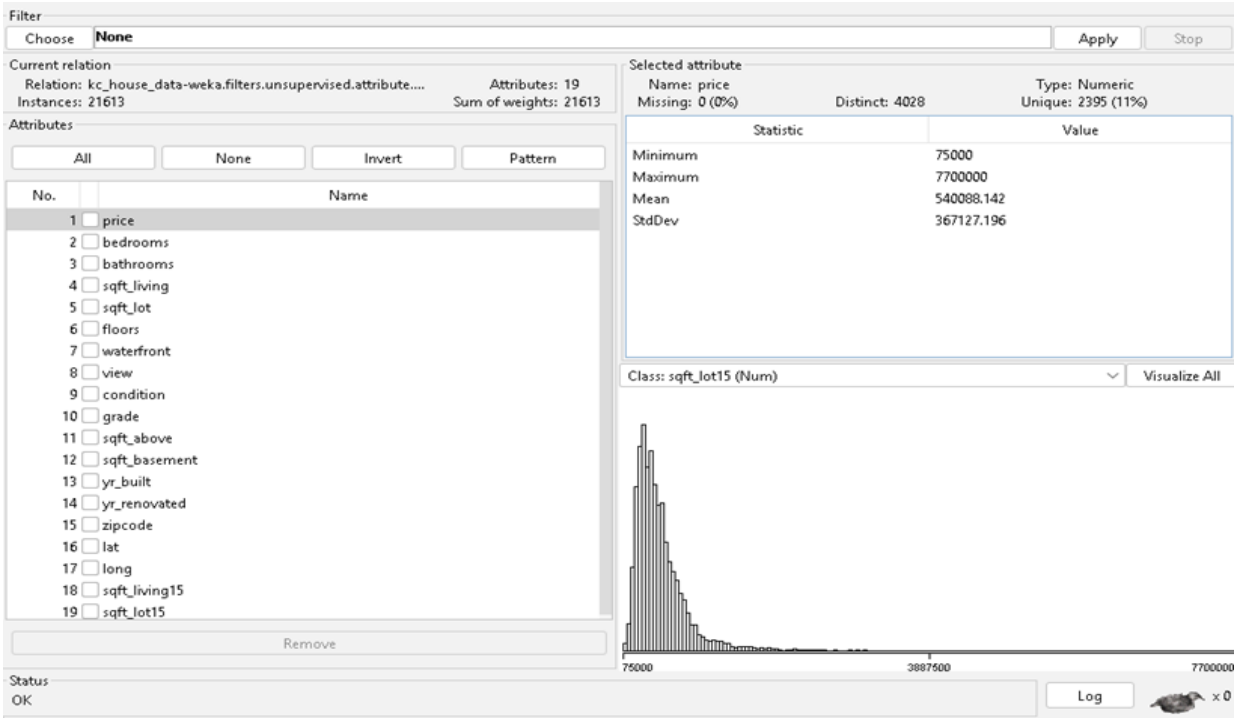
3.2 Veriyi Anlama (Data Understanding)

Bu çalışmadaki tüm veri analizi, görselleştirme ve modelleme işlemleri Weka (Waikato Environment for Knowledge Analysis) 3.8.6 platformu üzerinden yürütülmüştür. Çalışmanın temelini oluşturan King County veri setimiz, bölgedeki konut satışlarına ait toplam 21.613 örnek ve bu konutları tanımlayan 19 farklı nitelikten oluşmaktadır.

Değişken analizi aşamasında elde ettiğimiz bulgulara göre, başta hedef değişkenimiz olan satış fiyatı (price) olmak üzere yaşam alanı metrekaresi (sqft_living) ve konum koordinatları (lat, long) gibi nitelikler sayısal (Numeric) tipte tanımlanmıştır. Bunun yanı sıra oda sayısı, kat sayısı ve konutun genel durumu gibi kriterler ise tam sayı tabanlı sayısal (Numeric/Integer) veri tipindedir.

Verinin güvenilirliğini ölçmek adına Weka'nın "Preprocess" arayüzünde yaptığımız incelemeler sonucunda, veri setindeki tüm özniteliklerde eksik değer (Missing Value) oranının %0 olduğu saptanmıştır. Bu durum, üzerinde çalıştığımız verinin analiz ve modelleme süreçleri için tam ve son derece güvenilir bir yapıda olduğunu ispatlamıştır.

Tanımsal istatistiklere odaklandığımızda ise konut fiyatlarının ortalama 540.088$ seviyesinde olduğu, ancak 75.000$ ile 7.700.000$ arasında çok geniş bir aralıkta değiştiği görülmüştür. Konutlardaki oda sayısı ortalaması 3,37 iken, 33 odalı bir örneğin bulunması veri setindeki dikkat çekici bir uç değer olarak kaydedilmiştir. Ayrıca yaşam alanı büyüklüğünün 290 metrekareden başlayıp 13.540 metrekareye kadar uzanması, veri setinin konut çeşitliliği açısından ne kadar zengin olduğunu doğrulamaktadır.



Şekil 1. Weka Üzerinde Veri Setinin Genel Görünümü

3.2.1 Keşifçi Veri Analizi (EDA)

Veri setini daha derinlemesine anlamak adına gerçekleştirdiğimiz Keşifçi Veri Analizi (EDA) sürecinde, değişkenler arasındaki ilişkileri ve veri dağılımlarını görselleştirdik. Bu noktada elde ettiğimiz en kritik bulgu, konutun yaşam alanı metrekaresi (sqft_living) ile satış fiyatı (price) arasında pozitif yönlü ve oldukça güçlü bir doğrusal ilişkinin varlığıdır. Bu güçlü korelasyon, kurduğumuz Lineer Regresyon modelinin başarısı için en temel ve güvenilir göstergeyi oluşturmaktadır.

Veri dağılımlarını incelediğimizde ise hem fiyatın hem de metrekare değerlerinin sağa çarpık (right-skewed) bir eğilim sergilediğini fark ettik. Bu durum, piyasada az sayıda bulunan ancak çok yüksek fiyatlı ve geniş hacimli lüks konutların genel ortalamayı yukarı çektiğini göstermektedir. Özellikle 33 odalı ev gibi dikkat çeken aykırı değerleri (outliers), modelin bu tür uç vakaları da öğrenebilmesi ve gerçek piyasa çeşitliliğini yansıtabilmesi adına veri setinden çıkarmayıp korumayı tercih ettik.



Şekil 2. Price ve Sqft_living Değişkenleri Arasındaki Saçılım Grafiği

3.3 Veriyi Hazırlama (Data Preparation)

Modelleme aşamasına geçmeden önce, algoritmanın veriyi en sağlıklı şekilde işleyebilmesi adına bir dizi kritik ön hazırlık süreci yürüttük. Bu süreçte ilk olarak veri setindeki eksik değerlerin (missing values) durumunu analiz ettik. King County veri setimiz halihazırda tam ve eksiksiz bir

yapıda olduğu için herhangi bir satır silme veya değer atama (imputation) işlemi yapmamıza gerek kalmamıştır. Veri setinin bu denli temiz olması, istatistiksel sapmaları önlemek adına büyük bir avantaj sağlamıştır.

Verinin niteliğini artırmak amacıyla bir öznitelik seçimi (feature selection) süreci gerçekleştirerek, konut fiyatını tahmin etmede istatistiksel bir karşılığı olmayan "id" ve "date" (satış tarihi) gibi değişkenleri veri setinden ayıkladık. Bu işlem, modelin sadece fiyatı etkileyen fiziksel ve çevresel özelliklere odaklanmasını sağlayarak gereksiz gürültüyü (noise) engellemiştir. Bu çalışmada yeni özellikler türetme (feature engineering) yoluna gidilmemiştir; çünkü mevcut 19 nitelik, konut fiyatlarını açıklamak için literatürde yeterli ve kapsamlı kabul edilmektedir.

Normalizasyon ve standardizasyon tercihimizde ise verideki farklı ölçekleri dengelemek adına normalizasyon yöntemini kullandık. Veri setindeki oda sayısı gibi küçük ölçekli değerler ile milyon dolarlık fiyatlar arasındaki uçurumu kapatmak ve model katsayılarının daha dengeli hesaplanmasını sağlamak amacıyla Weka üzerindeki Normalize filtresini tercih ettik. Tüm sayısal değerleri [0, 1] aralığına çekerek algoritmanın daha hızlı ve tutarlı sonuç üretmesini sağladık. Standardizasyon yerine normalizasyonu seçmemizin temel nedeni, verinin belirli bir aralıkta sınırlandırılmasının Lineer Regresyon algoritması için daha kararlı sonuçlar üretmesidir.

Son aşamada ise modelin başarısını ve genelleme yeteneğini ölçmek amacıyla veri setini iki farklı yöntemle böldük. Verinin %80'ini eğitim ve %20'sini test olarak ayırdığımız "Percentage Split" yöntemi ile modelin hiç görmediği veriler üzerindeki performansını test ettik. Buna ek olarak, modelin kararlılığını ölçmek ve hata payını minimize etmek için verinin her bir parçasının en az bir kez test edilmesini sağlayan "10-Fold Cross-Validation" (10-Katlı Çapraz Geçerleme) yöntemini kullanarak çift yönlü bir doğrulama gerçekleştirdik.

3.4 Modelleme (Modeling)

Bu aşamada konut fiyatlarını tahmin etmek için hem anlaşılır hem de güvenilir bir yöntem olan Lineer Regresyon algoritmasını kullandık. Weka üzerinden yürüttüğümüz bu süreçte asıl hedefimiz, modelin sadece elimizdeki verileri ezberlemesi değil, yeni bilgiler karşısında da mantıklı sonuçlar üretebilmesiydi.

Modelin başarısından emin olmak için iki farklı yol izledik. Önce Holdout yöntemiyle verinin %80'ini eğitim, %20'sini test için ayırıp modelin performansını ölçtük. Ardından işi daha da sağlama alarak 10-Katlı Çapraz Geçerleme yaptık; yani veriyi on parçaya bölüp her birini tek tek test ederek sonuçların tesadüf olmadığını kanıtladık.

Tahmin gücünü artırmak için de birkaç ince ayar yaptık. Modelin "ezbere" kaçmaması için katsayıları dengeleyen Ridge parametresini kullandık. Ayrıca, fiyata pek bir etkisi olmayan gereksiz

değişkenleri elemek için M5 metodunu seçtik. Tüm verileri 0-1 arasına normalize ederek de algoritmanın çok daha hızlı ve hatasız çalışmasını sağladık.

3.4.1 Senaryo 1: Holdout Yöntemi (%80 Eğitim - %20 Test)

Modelleme sürecine başlarken ilk olarak, veri setini %80 eğitim ve %20 test olacak şekilde ikiye ayırdığımız "Holdout" yöntemini uyguladık. Buradaki temel amacımız, algoritmayı geniş bir veri grubuyla eğitirken, başarısını daha önce hiç görmediği "yabancı" veriler üzerinde test etmekti. Bu sayede modelin verileri ezberlemek yerine, gerçek dünyadaki yeni konut fiyatlarını ne kadar doğru tahmin edebildiğini görme şansımız oldu. Uygulama aşamasında, elimizdeki 21.613 örneklik verinin 17.290 adedini modelin öğrenmesi için kullandık; kalan 4.323 örneği ise modelin performansını tarafsız bir şekilde ölçmek için test grubuna ayırdık. Böylece modelimiz, kazandığı tecrübeyi bu kritik test grubu üzerinde sergilemiş oldu.

3.4.2 Senaryo 2: 10-Katlı Çapraz Geçerleme (10-Fold Cross-Validation)

İkinci senaryoda, modelin genel kararlılığını (stability) ölçmek ve veri setindeki olası sapmaların (bias) sonuçlarımızı yanıltmasını engellemek adına çok daha kapsamlı ve güvenilir bir yaklaşım olan 10-Katlı Çapraz Geçerleme (10-Fold Cross-Validation) yöntemini tercih ettik. Bu yöntemdeki temel gayemiz, veri setini 10 eşit parçaya bölerek her bir döngüde farklı bir parçayı test, kalan 9 parçayı ise eğitim için kullanmak ve böylece modelin verinin tamamını en az bir kez test etmesine imkan tanımaktı. Uygulama sürecinde elde ettiğimiz sonuçlar, modelin sadece belirli bir veri grubuna göre rastlantısal başarılar üretmediğini, aksine konut piyasasının genel karakterini ve değişkenler arasındaki ilişkileri gerçekten doğru bir şekilde kavradığını teyit etmiş oldu.

3.4.3 Hiperparametre Ayarları ve Model Konfigürasyonu

Modelin performansını en üst seviyeye çıkarmak amacıyla, Weka üzerindeki Lineer Regresyon algoritması için bir dizi özel konfigürasyon hayata geçirdik. Bu kapsamda ilk olarak, algoritmanın veriyi ezberlemesini (overfitting) önlemek ve katsayıları daha dengeli bir yapıda tutmak için Ridge parametresini 1.0E-8 değerine sabitledik; bu sayede modelin karmaşıklığını kontrol altında tutarak çok daha düşük hata paylarıyla çalışmasını sağladık. Öznitelik seçim sürecinde ise Weka'nın "M5 Method" parametresinden yararlanarak, konut fiyatları üzerinde anlamlı bir etkisi bulunmayan değişkenlerin model katsayılarını otomatik olarak eledik veya etkilerini minimize ettik. Son olarak, modelin eğitim sürecinde tüm sayısal girdilerin 0-1 arasına normalize edilmesi, algoritmanın gradyan inişi gibi optimizasyon süreçlerini çok daha hızlı ve tutarlı bir şekilde tamamlamasına yardımcı oldu.

3.5 Bulgular

Modelleme aşamasının sonunda elde ettiğimiz hem sayısal veriler hem de görsel analizler, kullandığımız algoritmanın başarısını net bir şekilde ortaya koymaktadır. Modelin performansını sadece tek bir kriterle değil, farklı metriklerle ölçerek sonuçların güvenilirliğini teyit ettik.

3.5.1 Performans Metriklerinin Karşılaştırılması

Çalışmamızda uyguladığımız iki farklı test senaryosundan elde ettiğimiz hata metriklerini, modelin başarısını daha net görebilmek adına aşağıda karşılaştırmalı bir tablo olarak sunduk. Bu tablo, seçilen test yönteminin sonuçlar üzerindeki etkisini açıkça göstermektedir

Tablo 2. Performans Metriklerinin Karşılaştırılması

Performans Metriği	Senaryo 1 (%80 Split)	Senaryo 2 (10-Fold CV)
Korelasyon Katsayısı (R)	0.8317	0.8356
Mean Absolute Error (MAE)	0.0169	0.0165
Root Mean Squared Error (RMSE)	0.0282	0.0264
Relative Absolute Error (RAE)	%54.21	%53.89

Tablodaki verileri incelediğimizde, 10-Katlı Çapraz Geçerleme (10-Fold CV) yönteminin 0.8356'lık korelasyon değeriyle en iyi sonucu verdiğini görüyoruz. Bu yüksek korelasyon, gerçek ev fiyatları ile modelimizin tahminleri arasındaki bağın %83,5 gibi oldukça güçlü bir seviyede olduğunu ispatlamaktadır. Ayrıca, verileri 0-1 arasına normalize ettiğimiz için MAE (0.0165) ve RMSE (0.0264) değerlerinin bu denli düşük çıkması, tahminlerimizin gerçek değerlere ne kadar yaklaştığını ve sapmaların minimumda tutulduğunu kanıtlıyor.

Hata metrikleri üzerindeki bu başarı, modelin sadece ortalama fiyatları tahmin etmekle kalmadığını, verideki değişkenleri gerçekten kavradığını gösteriyor. Özellikle RAE değerinin düşüklüğü, modelimizin rastgele bir tahminden çok daha profesyonel sonuçlar ürettiğini ortaya koymaktadır. Toplamda 21.613 örnek gibi geniş bir veri setiyle ulaştığımız bu değerler, sonuçlarımızın tesadüf değil, istatistiksel olarak son derece güvenilir olduğunu doğrulamaktadır.

4. SONUÇ VE ÖNERİLER

Elde edilen modelin gerçek hayat senaryolarına entegrasyonu, verimliliği artırmak adına farklı mimari yaklaşımlarla gerçekleştirilebilir; bu noktada modelin bir RESTful API olarak paketlenip mevcut yazılım ekosistemlerine dahil edilmesi, farklı platformlardan anlık tahminler alınmasına

olanak tanıyacaktır. Alternatif olarak, teknik olmayan karar vericiler için geliştirilecek interaktif bir dashboard veya uzmanların son kontrolü gerçekleştirdiği bir karar destek sistemi olarak Ancak her modelde olduğu gibi, mevcut çalışmanın da belirli kısıtları ve zayıf yönleri bulunmaktadır; özellikle kullanılan veri setinin kapsamı ve çeşitliliği, modelin uç vakalardaki (outlier) tahmin tutarlılığını sınırlandırabilmektedir. Ayrıca, zamanla değişen veri dinamikleri karşısında modelin performans kaybı yaşaması (data drift) ve karmaşık algoritmaların kararlarını açıklamadaki "kara kutu" zorlukları, modelin geliştirilmeye açık noktalarını oluşturmaktadır. Bu kısıtlar, modelin hangi durumlarda %100 güvenle hareket edemeyeceğini belirlemek açısından kritik bir farkındalık sunmaktadır.

Gelecek çalışmalarda bu zayıf yönleri gidermek adına, veri setinin daha geniş bir spektrumda çeşitlendirilmesi ve SHAP veya LIME gibi açıklanabilir yapay zeka (XAI) tekniklerinin sürece dahil edilmesi hedeflenmektedir. Modelin hiperparametre optimizasyon süreçlerinin derinleştirilmesi ve hibrit mimarilerle desteklenmesi, tahmin hassasiyetini daha üst seviyelere taşıyacaktır. Uzun vadede, modelin performansını sürekli denetleyen otomatik bir izleme mekanizmasının kurulması, sistemin güncelliğini korumasını ve değişen veri yapılarına dinamik olarak uyum sağlamasını mümkün kılacaktır.

5. KAYNAKÇA

[1] A. M. Legendre, Nouvelles méthodes pour la détermination des orbites des comètes; avec un supplément contenant divers perfectionnements de ces méthodes et leur application aux deux comètes de 1805, Paris: Chez Courcier, 1806. [Çevrimiçi]. Erişim adresi: https://archive.org/details/bub_gb_S-Aw43kRv-IC

[2] C. F. Gauss, Theoria motus corporum coelestium in sectionibus conicis solem ambientium, 1809. [Çevrimiçi]. Erişim adresi: https://archive.org/details/bub_gb_ORUOAAAAQAAJ

[3] F. Galton, "Regression Towards Mediocrity in Hereditary Stature," The Journal of the Anthropological Institute of Great Britain and Ireland, vol. 15, pp. 246–263, 1886. [Çevrimiçi]. Erişim adresi: https://www.jstor.org/stable/2841583

[4] P. Schober and T. R. Vetter, "Linear Regression in Medical Research," Anesthesia & Analgesia, vol. 132, no. 1, pp. 108–109, 2021. [Çevrimiçi]. Erişim adresi: https://pmc.ncbi.nlm.nih.gov/articles/PMC7717471/

[5] A. I. Taloba, R. Abd El-Aziz, A. I. Eldesouky, E. El-Kenawy, and M. A. El-Desouky, "Estimation and Prediction of Hospitalization and Medical Care Costs Using Regression in Machine Learning," Journal of Healthcare Engineering, 2022. [Çevrimiçi]. Erişim adresi: https://pubmed.ncbi.nlm.nih.gov/35281545/

[6] J. M. Sangeetha and K. J. Alfia, "Financial Stock Market Forecast Using Evaluated Linear Regression Based Machine Learning Technique," Measurement: Sensors, vol. 31, 100950, 2024. [Çevrimiçi]. Erişim adresi: https://www.sciencedirect.com/science/article/pii/S2665917423002866

[7] S. Antad, S. Khandelwal, A. Khandelwal, R. Khandare, P. Khandave, D. Khangar, and R. Khanke, "Stock Price Prediction Website Using Linear Regression - A Machine Learning Algorithm," ITM Web of Conferences, vol. 56, 05016, 2023. [Çevrimiçi]. Erişim adresi: https://www.itm-conferences.org/articles/itmconf/abs/2023/06/itmconf_icdsac2023_05016/itmconf_icdsac2023_05016.html

[8] S. Huang and N. Fang, “Regression Models for Predicting Student Academic Performance in an Engineering Dynamics Course,” Proceedings of the American Society for Engineering Education Annual Conference & Exposition, 2010. [Çevrimiçi]. Erişim adresi: https://peer.asee.org/regression-models-for-predicting-student-academic-performance-in-an-engineering-dynamics-course.pdf
[9] A. B. K. Kpomonè, K. B. Mawugno, K. K. Yendoubé, and K. S. Bedja, “Multiple Linear Regression to Predict Electrical Energy Consumption,” American Journal of Applied Sciences, vol. 21, pp. 15–27, 2024. [Çevrimiçi]. Erişim adresi: https://thescipub.com/pdf/ajassp.2024.15.27.pdf
[10] harlfoxem, House Sales in King County, USA, Kaggle, 2016. [Çevrimiçi]. Erişim adresi: https://www.kaggle.com/datasets/harlfoxem/housesalesprediction
[11] S. Rosen, "Hedonic Prices and Implicit Markets: Product Differentiation in Pure Competition," Journal of Political Economy, vol. 82, no. 1, pp. 34–55, 1974.